



SENAC CAS

Simulação com modelagem, operação e gestão I

Sistema de Classificação de Produtos em Tempo Real com IA e Esteira Transportadora.

Beatriz Bardela Dos Santos
Gustavo Alves Marcelino
Kevin Kawan Dias Pereira
Matheus Farias Dos Santos
Tiago José Batschke De Souza

Sumário

1	Introdução	2
2	Metodologias	3
2.1	O que é uma Machine Learning?	3
2.2	Desvendando o TensorFlow: Da Teoria à Implementação	6
2.3	Shield Industrial OPS010	7
2.3.1	Programação Open Source e Suporte	7
3	Proposta de um Sistema de Classificação Inteligente: Visão Computacional e IA	8
4	Pesquisa e Montagem da Esteira	9
5	Progresso no Treinamento da Inteligência Artificial	10
6	Adição do Separador e Lógica de Classificação Aprimorada	12
7	Arquitetura de Comunicação e Gerenciamento de Dados	12
8	Aprimoramento da Interface e Acessibilidade	13
9	Conclusão	14

1 Introdução

A crescente demanda por eficiência e qualidade na indústria tem impulsionado a adoção de tecnologias avançadas, como a Inteligência Artificial (IA) e a visão computacional, para otimizar processos de produção e controle. Neste contexto, este pré-projeto descreve a concepção e o desenvolvimento de um sistema inovador de classificação de produtos em tempo real, utilizando uma esteira automatizada integrada a um modelo de IA baseado em visão computacional. O objetivo principal é criar um sistema eficiente e preciso que otimize o processo de inspeção de qualidade, classificando produtos como "aptos para venda" ou "não aptos para venda", visando a redução de custos e o aprimoramento da qualidade final dos produtos, o coração deste sistema reside na capacidade da IA de analisar visualmente os produtos em movimento na esteira transportadora. Para tal, empregou-se a biblioteca de código aberto Teachable Machine para o treinamento de redes neurais, abordando as complexidades de diferentes condições de iluminação através de uma vasta base de dados gerada sinteticamente. A esteira, desenvolvida com um protótipo em MDF, garante o transporte contínuo e a exposição adequada dos produtos à câmera de captura, além da automação da inspeção visual, o projeto contempla a integração robusta dos dados. Um código em Python, utilizando as bibliotecas Flask e mysql.connector, foi desenvolvido para permitir que a IA se comunique diretamente com um banco de dados MySQL. Isso garante o armazenamento seguro e acessível das classificações, permitindo o monitoramento e a análise contínua dos resultados. A visualização desses dados é consolidada em uma dashboard intuitiva, que oferece uma visão clara e em tempo real do desempenho do sistema de classificação este trabalho demonstra a viabilidade de um sistema automatizado que não apenas agiliza o controle de qualidade, mas também eleva a padronização e a confiabilidade na identificação de produtos, representando um avanço significativo para aplicações industriais que demandam inspeção visual em larga escala.

2 Metodologias

2.1 O que é uma Machine Learning?

Machine learning ou ML é a prática de ajudar softwares a realizar tarefas sem programação ou regras explícitas. Na programação tradicional, um desenvolvedor especifica regras que o computador precisa seguir. Porém, ML demanda uma mentalidade diferente. No mundo real, o foco de ML é mais na análise de dados do que na programação. Os desenvolvedores fornecem exemplos, e o computador aprende padrões a partir dos dados. Pense em machine learning como "programação com dados". Lembrando que Machine learning é um subconjunto da inteligência artificial. O aprendizado de máquina permite que os sistemas de computador se ajustem e se aperfeiçoem continuamente à medida que acumulam mais "experiências". Assim, o desempenho desses sistemas pode ser melhorado, fornecendo conjuntos de dados maiores e mais variados para processamento.

- **A importância do machine learning:**

A taxa de geração de dados está acelerando a cada dia. O mundo está criando mais dados todos os dias do que nunca. Seria quase impossível analisar e utilizar todos esses dados sem o machine learning. Por isso, o machine learning está abrindo um novo horizonte do que os humanos podem fazer com computadores e outras máquinas. O machine learning ajuda as empresas com funções importantes, como detecção de fraudes, identificação de ameaças à segurança, personalização e recomendações, atendimento ao cliente automatizado por meio de chatbots, transcrição e tradução, análise de dados e muito mais. O aprendizado de máquina também está impulsionando a inovação empolgante do futuro, como veículos autônomos, drones e aviões, realidade aumentada e virtual e robótica.

- **Qual é a diferença entre machine learning, inteligência artificial e aprendizado profundo?**

Embora inteligência artificial (IA) e machine learning (ML) sejam usados como sinônimos, eles não são termos iguais. A inteligência artificial é uma área da ciência da computação que se concentra na criação de computadores e máquinas capazes de raciocinar, aprender e agir de maneira semelhante à inteligência humana, ou sistemas que envolvem dados cuja escala excede o que os humanos podem analisar. O campo inclui muitas disciplinas diferentes, incluindo análise de dados, estatística, engenharia de hardware e software, neurociência e até mesmo filosofia. Enquanto a inteligência artificial é uma categoria ampla da ciência da computação, machine learning é uma aplicação de IA que envolve o treinamento de máquinas para executar uma tarefa sem programação específica. O machine learning é mais usado para extrair conhecimento dos dados com técnicas como redes neurais, aprendizado supervisionado e não supervisionado, árvores de decisão e regressão linear. Assim como machine learning é um subconjunto da inteligência artificial, o aprendizado profundo é um subconjunto do machine learning. O aprendizado profundo treina redes neurais em conjuntos de dados. Uma rede neural é um modelo que usa um sistema de neurônios artificiais que são nós computacionais usados para classificar e analisar dados. Os dados são inseridos na primeira camada de uma rede neural, e cada nó toma uma decisão e passa essa informação para vários nós na camada seguinte. Os modelos de treinamento com mais de três camadas são conhecidos como "redes neurais profundas" ou "aprendizado profundo". Algumas redes neurais modernas têm centenas ou milhares de camadas.

- **Tipos de machine learning**

Em geral, há quatro tipos de modelos usados em machine learning. O aprendizado supervisionado é um modelo de machine learning que usa dados de treinamento rotulados (dados estruturados) para mapear um atributo específico a um rótulo. No aprendizado supervisionado, a saída é conhecida (como o reconhecimento da imagem de uma maçã) e o modelo é treinado com dados da saída conhecida. Em termos simples, para treinar o algoritmo a reconhecer fotos de maçãs, alimente-o com fotos rotuladas como maçãs. O aprendizado não supervisionado é um modelo de machine learning que usa dados não rotulados (dados não estruturados) para aprender padrões. Ao contrário do aprendizado supervisionado, a “correção” da saída não é conhecida antecipadamente. Em vez disso, o algoritmo aprende com os dados sem contribuição humana (ou seja, não supervisionado) e os categoriza em grupos com base em atributos. Por exemplo, se o algoritmo receber fotos de maçãs e bananas, ele vai trabalhar sozinho para categorizar qual foto é uma maçã e qual é uma banana. O aprendizado não supervisionado é bom em modelagem descritiva e correspondência de padrões. Aprendizado Semi-supervisionado, em sistemas que utilizam técnicas de aprendizado semi-supervisionado, temos uma situação onde uma parte dos dados é rotulada e outra parte não é rotulada. Por exemplo a Netflix, onde os dados rotulados seriam as classificações dos usuários em relação aos filmes e séries assistidos, enquanto os dados não rotulados seriam os filmes e séries não avaliados por eles, e por fim aprendizado por reforço, no aprendizado por reforço, um agente é treinado para tomar sequências de decisões, recebendo recompensas ou penalidades em troca. É o caso do AlphaGo, um programa de inteligência artificial que aprendeu a jogar o jogo de tabuleiro Go. O AlphaGo analisou milhões de jogos disponíveis para descobrir as melhores estratégias de vitória. Em seguida, jogou milhões de partidas contra si mesmo, aprimorando suas habilidades e aprendendo as jogadas que levavam à vitória.




Figura 1: Alguns exemplos de como o Machine Learning pode ser utilizado:

- **Vantagens do machine learning:**

Reconhecimento de padrões: Quanto mais dados forem consumidos por um algoritmo de machine learning, melhor será a capacidade de encontrar tendências e padrões nesses dados. Por exemplo, um site de e-commerce pode usar machine learning para entender como as pessoas compram e aproveitar essas informações para oferecer recomendações melhores ou encontrar dados de tendências que podem levar a oportunidades de novos produtos.

Automação: O machine learning e a inteligência artificial podem eliminar grande parte do trabalho monótono dos trabalhadores humanos. Utilitários como a automação de processos robóticos podem realizar algumas das tediosas tarefas de negócios que impedem as pessoas de realizar trabalhos mais significativos. Os algoritmos de visão computacional e detecção de objeções podem ajudar os robôs a escolher e embalar itens de uma linha de montagem. O machine learning sempre ativado para detecção de fraudes e avaliação de ameaças pode encontrar falhas de segurança antes que elas se tornem um problema.

Melhoria contínua: Com os tipos certos de dados, os algoritmos de machine learning vão continuar melhorando para serem mais rápidos e precisos. Um bom exemplo é o conjunto de dados da GPT-3, que continua a melhorar a forma como gera texto.

- **Desvantagens do machine learning:**

Potencial de viés: O desempenho do machine learning depende dos dados fornecidos. Se um algoritmo de machine learning for alimentado com um conjunto de dados enviesado, ele vai fornecer resultados enviesados.

Aquisição de dados: O machine learning pode precisar de muitos dados para ser útil. Como muitos casos de uso de machine learning são baseados em aprendizado supervisionado, adquirir e limpar dados estruturados para treinar os algoritmos é uma primeira etapa importante, o que pode ser difícil se os dados estiverem em vários locais isolados dentro de uma organização.

Conhecimentos técnicos necessários: Enquanto o machine learning, a inteligência artificial e os fornecedores de nuvem tentam facilitar ao máximo a configuração e a execução de algoritmos de machine learning, as organizações geralmente precisam de programadores e cientistas de dados para entender e utilizar os algoritmos de treinamento e os resultados deles.

Uso intensivo de recursos: O machine learning pode ser demorado, exigindo muitos recursos de computação e horas dos funcionários para começar a processar dados e alcançar resultados.

Confira alguns exemplos de uso do machine learning:

- **Automação de processos robóticos:** A RPA combinada com machine learning cria uma automação inteligente capaz de automatizar tarefas complexas, como o processamento de aplicativos de hipoteca.
- **Otimização de vendas:** Os dados do cliente podem treinar algoritmos de machine learning para análise de sentimento dos clientes, análise de previsão de vendas e previsão de desligamento de clientes.
- **Atendimento ao cliente:** Aplicativos de machine learning incluem bots de chat e assistentes virtuais automatizados para automatizar tarefas de rotina de atendimento ao cliente e acelerar a resolução de problemas.

- **Segurança:** O machine learning ajuda as empresas a melhorar os recursos de análise de ameaças e como elas respondem a ataques cibernéticos, hackers e malwares.
- **Marketing digital:** O machine learning permite que os profissionais de marketing identifiquem novos clientes e ofereçam os materiais de marketing certos para as pessoas certas no momento certo.
- **Prevenção de fraude:** O machine learning ajuda empresas de cartão de crédito e bancos a analisar grandes quantidades de dados transacionais para identificar atividades suspeitas em tempo real.

2.2 Desvendando o TensorFlow: Da Teoria à Implementação

O TensorFlow, uma plataforma robusta de código aberto, revolucionou o campo do aprendizado de máquina. Sua arquitetura flexível permite a criação de modelos complexos e eficientes, desde redes neurais profundas até algoritmos de aprendizado por reforço. Essa versatilidade, combinada com uma comunidade ativa de desenvolvedores, torna o TensorFlow uma escolha popular para pesquisadores e empresas que buscam soluções de inteligência artificial.



Figura 2: TensorFlow

Lendo a documentação da biblioteca podemos encontrar aba de “demonstrações” e temos algumas opções de ML e todas sendo bem interessantes temos por exemplo controlador da webcam que segundo o site usa imagens treinadas no navegador para jogar Pac-Man, tem a Move Mirror que basicamente captura seus movimentos por meio da câmera do computador, temos a previsão de arremessos com Node.js que é um modelo hospedado para simular a direção e tipos de arremessos de beisebol e por fim temos a qual provavelmente implementaremos no projeto a Teachable Machine que basicamente vai ensinar a máquina a reconhecer imagens e tocar sons. Falando um pouco sobre o modelo escolhido temos algumas orientações a serem seguidas e que foram informadas.

- Reúna e agrupe seus exemplos em classes ou categorias que você deseja que o computador aprenda.
- Treine seu modelo e teste-o imediatamente para ver se ele consegue classificar corretamente novos exemplos.

- Exporte seu modelo para seus projetos: sites, apps e mais. Você pode baixar seu modelo ou hospedá-lo online.

Como pode ser feito seu aprendizado?

- **Imagens:** Ensine um modelo a classificar imagens usando arquivos ou sua webcam.
- **Sons:** Ensine um modelo a classificar áudio gravando pequenas amostras de som.
- **Posses:** Ensine uma modelo a classificar posições corporais usando arquivos ou poses marcantes na sua webcam.

2.3 Shield Industrial OPS010

Desenvolvida para simplificar a implementação de projetos industriais, a Shield Industrial OPS010 é 100 por cento compatível com Arduino, facilitando a programação e integração com outros sistemas. Seu hardware robusto, projetado para suportar as condições mais exigentes, garante a confiabilidade em ambientes industriais. A modularidade da placa permite a expansão de funcionalidades, oferecendo flexibilidade para diferentes aplicações.

Recursos Principais:

- Compatibilidade com ESP32: Permite a integração com um poderoso módulo processador
- Hardware Industrial: Projetado para suportar condições adversas
- Proteção e Estabilidade: Garante a segurança e o bom funcionamento do sistema
- Comunicação Versátil: Inclui interface RS485 e TTL para displays
- Entradas e Saídas: 8 entradas digitais, 8 saídas digitais, 1 entrada analógica e 1 saída analógica
- Desenvolvimento ágil e eficiente
- Confiabilidade em ambientes industriais
- Acesso a uma comunidade ativa e suporte especializado
- Flexibilidade para diversas aplicações industriais

2.3.1 Programação Open Source e Suporte

A OPS010 utiliza programação open source, facilitando o desenvolvimento e o acesso a uma vasta comunidade de conhecimento. A Oppler oferece suporte técnico especializado, desde a especificação do projeto até as melhores práticas de programação industrial.



Figura 3: OPS010

3 Proposta de um Sistema de Classificação Inteligente: Visão Computacional e IA

Este projeto tem como objetivo principal o desenvolvimento de uma esteira automatizada para teste de qualidade, utilizando a placa Shield Industrial OPS010. O desafio central reside na integração de inteligência artificial (IA) à esteira, permitindo a classificação precisa de produtos como 'aptos para venda' ou 'não aptos para venda'. Para a implementação dos testes de visão computacional, exploraremos a linguagem de programação Python, reconhecida por sua robustez e versatilidade em aplicações de IA.

A pesquisa inicial envolve a análise de artigos e blogs relevantes, visando a criação de um protótipo funcional. O desenvolvimento do projeto será realizado de forma iterativa, com aprimoramentos contínuos a partir do protótipo inicial.

A imagem apresenta um modelo conceitual da esteira, desenvolvido no SolidWorks. É importante ressaltar que este protótipo não representa o design final do equipamento, servindo apenas como uma ilustração inicial do conceito.




Figura 4: Esta imagem representa um protótipo inicial da esteira, não refletindo o design final do projeto.

Este quadro Kanban no GitHub representa a organização visual das etapas do nosso projeto 'Testes de Qualidade com Visão Computacional'. Ele nos permite acompanhar o

progresso das tarefas, desde a concepção de novas ideias até a implementação e validação final.




Figura 5: Kanban no GitHub



Figura 6: QR-code com Kanban no GitHub

4 Pesquisa e Montagem da Esteira

A fase de pesquisa e montagem da esteira foi crucial para o desenvolvimento do protótipo do sistema de classificação inteligente. Esta etapa envolveu uma série de atividades iterativas, desde a modelagem conceitual até os ajustes finais na estrutura física.

Inicialmente, foram realizadas simulações do modelo da esteira no SolidWorks, permitindo uma visualização tridimensional e a verificação de aspectos de design e funcionalidade antes da fabricação. A pesquisa de motores adequados para a esteira também foi um ponto importante, visando garantir a movimentação eficiente e confiável do sistema.

A confecção da estrutura da esteira passou por algumas adaptações em relação aos materiais. Primeiramente, considerou-se o corte da esteira em MDF de 6mm. No entanto, para otimizar o projeto, as medidas foram refeitas para MDF de 3mm.

Durante a montagem, diversos desafios foram encontrados e superados:

- A montagem inicial apresentou-se incompleta, demandando reajustes na estrutura da esteira.
- A tentativa de impressão da bobina em uma impressora 3D de filamento resultou em uma impressão incompleta devido a uma máquina desregulada.

- Para contornar o problema da impressão 3D, a bobina foi montada utilizando MDF de 6mm.
- A montagem geral e os reajustes foram realizados para garantir o alinhamento e o funcionamento correto dos componentes.
- Foi feito o desenho do corte do suporte da câmera, que seria essencial para a implementação da visão computacional.
- A medição e o corte do tecido para a esteira foram executados com precisão.
- Reajustes na fixação do motor foram necessários para assegurar sua estabilidade e desempenho.
- A verificação do rolamento do motor foi realizada para garantir um movimento suave da esteira.
- Por fim, a implementação do suporte na esteira foi concluída, integrando o componente vital para a captura de imagens.
- Novos reajustes na fixação do motor foram feitos para otimizar o funcionamento.

A Figura 5, apresentada anteriormente, ilustra um protótipo inicial da esteira, não representando o design final, mas servindo como uma base para as etapas de montagem e aprimoramento.




Figura 7: Esteira projetada no solid works

5 Progresso no Treinamento da Inteligência Artificial

O desenvolvimento da inteligência artificial para o sistema de classificação de produtos foi um processo iterativo, marcado por etapas de treinamento e aprimoramento da base de

dados. As reuniões de acompanhamento foram fundamentais para direcionar o progresso e tomar decisões cruciais ao longo do caminho.

Em 3 de maio de 2025, foi iniciada a fase de treinamento da IA com foco em visão computacional, utilizando a biblioteca de código aberto Teachable Machine. Nesta etapa inicial, duas redes neurais foram configuradas, denominadas "apto para venda" e "não apto para venda", e cada uma foi alimentada com um conjunto inicial de 800 fotos para treinamento.

Uma semana depois, em 10 de maio de 2025, o projeto avançou com um significativo aumento da base de dados de imagens. O número de fotos para o treinamento da IA foi expandido para aproximadamente 3.500 imagens em cada rede neural ("apto para venda" e "não apto para venda"). Este acréscimo visava aprimorar substancialmente a capacidade de reconhecimento da inteligência artificial, permitindo-lhe lidar com uma maior variedade de cenários e características dos produtos.

A reunião de 17 de maio de 2025 abordou a questão da robustez do modelo em diferentes condições de iluminação. Para isso, foi desenvolvido um código em Python, que utilizou as bibliotecas cv2, numpy e os. O objetivo principal deste código foi simular diversas condições de iluminação, gerando automaticamente imagens com "luz fraca", "luz forte", "alto contraste" e "baixo contraste". Esta simulação permitiu uma expansão massiva da base de dados, elevando o total de fotos para cada rede neural para aproximadamente 22.000 imagens. É importante ressaltar que, apesar da grande quantidade de dados gerados pela simulação, o grupo optou por manter a rede neural configurada anteriormente, devido à limitação da biblioteca em suportar o volume de fotos geradas para o novo treinamento.




Figura 8: Treinamento da rede neural com cerca de 7 mil fotos

Apesar do expressivo aumento no volume de dados gerados pela simulação, é crucial ressaltar que a rede neural inicialmente configurada foi mantida. Esta decisão foi tomada devido à limitação da biblioteca em suportar o vasto volume de fotos geradas para um novo treinamento completo. Com o modelo de IA devidamente treinado e robustecido, a próxima etapa crítica do projeto foi a integração do sistema de visão computacional com o banco de dados e a criação de uma interface para apresentação dos resultados, um código

em Python foi desenvolvido para permitir a comunicação bidirecional entre a Inteligência Artificial e o banco de dados. Para essa integração, foram empregadas as bibliotecas Flask e mysql.connector. A biblioteca Flask foi escolhida para a criação de um backend que atuasse como uma ponte, facilitando a comunicação da IA com sistemas externos. Por sua vez, mysql.connector possibilitou a conexão direta e a manipulação dos dados em um banco de dados MySQL. Para a gestão e armazenamento das respostas geradas pela IA, foi utilizado o Beekeeper em conjunto com um banco de dados disponibilizado pela própria faculdade. Essa estrutura garantiu que cada classificação de produto ("apto para venda" ou "não apto para venda") fosse devidamente registrada e acessível para análises futuras, finalmente, para a visualização clara e intuitiva dos resultados do sistema de classificação, foi desenvolvida uma dashboard esta interface gráfica permite o acompanhamento em tempo real do processo de inspeção de produtos, exibindo métricas de desempenho da IA, a quantidade de produtos classificados em cada categoria e eventuais tendências, proporcionando uma ferramenta essencial para o monitoramento e otimização do controle de qualidade.

6 Adição do Separador e Lógica de Classificação Aprimorada

Complementando a funcionalidade da esteira, um separador mecânico foi integrado ao sistema, crucial para a automação da distribuição dos produtos classificados. Este separador opera por meio de um sensor de proximidade, que se comunica diretamente com o ESP32 e, subsequentemente, com o Shield Industrial OPS010. Essa comunicação permite que o OPS010 gerencie o controle da esteira, pausando-a ou ajustando seu movimento conforme a necessidade de desvio do produto. A inteligência do sistema de separação não se baseia em uma única classificação instantânea. Em vez disso, a Inteligência Artificial (IA) realiza a classificação de cada produto, e a decisão de desvio é tomada com base em uma média das próximas 10 classificações. Isso significa que o sistema avalia um conjunto de produtos subsequentes para determinar a tendência predominante ("apto para venda" ou "não apto para venda") antes de acionar o separador. Se a maioria das 10 próximas classificações indicar que os produtos são "aptos para venda", o separador é acionado para direcioná-los para um lado específico da esteira. Caso a média aponte para "não aptos para venda", o separador os direciona para o lado oposto. Essa lógica de decisão aprimorada, baseada em um agrupamento de leituras, confere maior robustez ao processo de classificação e minimiza erros pontuais, garantindo uma segregação mais confiável dos produtos.

7 Arquitetura de Comunicação e Gerenciamento de Dados

Para assegurar uma comunicação eficiente e um gerenciamento otimizado dos dados gerados pela inteligência artificial, a arquitetura proposta integra a placa industrial Shield OPS010 com um módulo ESP32. Este último desempenha um papel fundamental na conectividade do sistema, sendo responsável por receber, via rede Wi-Fi, as informações processadas pela IA. A interface entre o módulo ESP32 e a IA é realizada por meio de uma aplicação desenvolvida em Flask, que atua como camada de comunicação entre os

dispositivos. Após a recepção dos dados, o Shield Industrial OPS010 assume o controle do processamento e do gerenciamento do fluxo de informações, direcionando-as para o banco de dados. A escolha do OPS010 deve-se à sua robustez, confiabilidade em ambientes industriais e compatibilidade com o ESP32, além de permitir um desenvolvimento ágil e seguro. Visando evitar a sobrecarga do sistema e garantir desempenho contínuo, foi implementada uma estratégia de gerenciamento cíclico do banco de dados. Assim que o volume de dados atinge aproximadamente 500 leituras, o OPS010 executa a exclusão dos registros antigos, iniciando um novo ciclo de armazenamento. Essa abordagem garante a manutenção de um volume de dados controlado, prevenindo a degradação do desempenho do sistema e otimizando os recursos de armazenamento. Além disso, prioriza a retenção dos dados mais recentes e relevantes para a operação em tempo real.

8 Aprimoramento da Interface e Acessibilidade

Para além da funcionalidade de registro e análise, a apresentação dos resultados da IA foi significativamente aprimorada. A dashboard, que visualiza o desempenho do sistema de classificação, foi desenvolvida com o uso do Flask, um framework web em Python. Este framework permitiu não apenas a construção de uma interface robusta, mas também a sua estilização, visando torná-la mais apresentável e de fácil entendimento para o usuário, a dashboard está hospedada em um servidor local, o que confere agilidade e controle sobre o ambiente de operação. Além disso, a configuração do servidor permite que qualquer dispositivo conectado à mesma rede local possa acessar a dashboard. Essa característica facilita o monitoramento e a colaboração em tempo real, permitindo que a equipe acompanhe as classificações e o desempenho do sistema de forma distribuída e eficiente, sem a necessidade de acesso externo.

9 Conclusão

Este trabalho demonstrou o desenvolvimento e a implementação de um sistema robusto e inovador para a classificação automática de produtos, integrando uma esteira automatizada com um sistema de visão computacional baseado em Inteligência Artificial. Desde a concepção do protótipo da esteira no SolidWorks e a seleção criteriosa de materiais como o MDF, até a complexa fase de treinamento da IA, cada etapa foi fundamental para a construção de uma solução eficiente e precisa. O treinamento da IA, iniciado com a biblioteca Teachable Machine, demonstrou a escalabilidade do modelo, partindo de 800 fotos e expandindo-se para aproximadamente 22.000 imagens por categoria através de simulações em Python para diversas condições de iluminação (luz fraca, luz forte, alto e baixo contraste). Essa abordagem multifacetada garante a robustez do sistema em variados ambientes de operação. A integração da IA com a esteira e o banco de dados é um ponto central do projeto. A utilização do Shield Industrial OPS010 em conjunto com o ESP32 para receber informações via Wi-Fi e gerenciar o banco de dados, com uma estratégia de limpeza de dados a cada 500 leituras, assegura a performance e a relevância dos registros em tempo real. Além disso, a inclusão do separador mecânico, acionado por um sensor de proximidade e operando com uma lógica de média das próximas 10 classificações, eleva a precisão na segregação dos produtos, minimizando erros pontuais e otimizando o fluxo de trabalho. Finalmente, a criação de uma dashboard intuitiva, desenvolvida com Flask e acessível via servidor local, não só demonstra a funcionalidade da IA em tempo real como também oferece uma ferramenta valiosa para monitoramento e análise contínua do processo de controle de qualidade, o sistema desenvolvido representa um avanço significativo na automação da inspeção visual, oferecendo uma solução viável para otimizar o controle de qualidade, reduzir custos e aumentar a padronização na classificação de produtos. Para trabalhos futuros, sugere-se a exploração de modelos de IA com maior capacidade de processamento para lidar com volumes ainda maiores de dados simulados, a implementação de mecanismos de feedback para aprimoramento contínuo do modelo e a expansão para a classificação de outros tipos de produtos ou defeitos mais complexos.

Referências

- [Alu25] Alura. *Visão Computacional com Teachable Machine*. Acessado em: 22 de Abril. 2025. URL: <https://www.alura.com.br/videos/visao-computacional-com-teachable-machine-c1466>.
- [Ciê20] Equipe de Ciência de Dados. *O que é aprendizado por transferência?* Acessado em: 22 de fevereiro. 7 de março de 2020. URL: <https://datascience.eu/pt/aprendizado-de-maquina/o-que-e-aprendizado-por-transferencia/>.
- [IBM25] IBM. *O que é visão computacional?* Acessado em: 23 de Abril. 2025. URL: <https://www.ibm.com/br-pt/topics/computer-vision>.
- [LAP18] LAPIX. *Deep Learning: Aprendizado por Transferência e Ajuste Fino*. Acessado em: 22 de fevereiro. 2018. URL: <https://lapix.ufsc.br/ensino/visao/visao-computacionaldeep-learning/deep-learningaprendizado-por-transferencia-e-ajuste-fino/>.
- [Mea19] Luis Meazzini. *Transfer Learning aplicado no reconhecimento de flores*. Acessado em: 22 de fevereiro. Maio de 2019. URL: <https://medium.com/ensina-ai/tutorial-transfer-learning-3972cac5e9b5>.
- [Opl25] Opller. *Shield Industrial OPS010*. Acessado em: 22 de fevereiro. 2025. URL: <https://opller.com/produtos/ops010/>.
- [ser25] servilub. *O que é esteira transportadora: tipos e pra que servem*. Acessado em: 1 de Maio. 2025. URL: <https://www.servilub.com.br/o-que-e-esteira-transportadora-tipos-e-pra-que-servem/>.
- [Sou22] Fábio Souza. *Como programar o ESP32 na Arduino IDE?* Acessado em: 4 de Maio. 28/06/2022. URL: <https://embarcados.com.br/como-programar-o-esp32-na-arduino-ide/>.

Conforme discutido em [Mea19], [Ciê20], [LAP18], [Opl25], [Alu25], [IBM25], [ser25], [Sou22],