

Saymon Jesus Souza, Enzo Malavazi

ESCRIBAS: Automação do Prontuário Médico via Reconhecimento de Fala

São Paulo

2025

Saymon Jesus Souza, Enzo Malavazi

ESCRIBAS: Automação do Prontuário Médico via Reconhecimento de Fala

Trabalho de Conclusão de Curso apresentado
ao Centro Universitário Senac, como requi-
sito parcial para obtenção do título de Ba-
charel em Engenharia da Computação.

Centro Universitário Senac
Engenharia da Computação

Orientador: Prof. Dr. Jorge Echeimberg

São Paulo
2025

Dedicamos este trabalho aos nossos familiares e amigos próximos,
que nos apoiaram de forma direta e indireta nesta jornada,
e aos professores do Centro Educacional Senac,
por transmitirem e compartilharem todo o conhecimento.

Agradecimentos

Agradecemos, em primeiro lugar, aos nossos familiares, pelo apoio incondicional durante esses cinco anos vividos intensamente no Centro Educacional Senac. Reconhecemos que a família é a base de toda a nossa estrutura emocional. Aos nossos professores, expressamos nossa sincera gratidão por todo o conhecimento transmitido e pelo suporte constante ao longo dessa jornada. Fomos a turma do período da pandemia e, mesmo diante das adversidades, os professores não desanimaram e não desistiram de nós.

Agradecemos especialmente aos professores:

- Jorge Echeimberg
- Ricardo Ciuccio
- Marcello Marcelino
- Rodrigo Mulinna
- Marcelo

Pela orientação fundamental nesta reta final, sempre dispostos a auxiliar e sanar nossas dúvidas. Estendemos nossos agradecimentos aos colegas Gregorio Alves, Felipe Mandelli, Thiago Thilove, Murilo Tibério, Gabriela Cordeiro e Luiz Guilherme, pela parceria e companheirismo ao longo desses cinco anos desafiadores. Por fim, nosso agradecimento especial aos nossos pais, esposas e filhos, por todo incentivo — seja ele financeiro, emocional ou espiritual —, que foi essencial para a realização deste trabalho e para a conclusão desta etapa tão importante em nossas vidas.

A grandeza não consiste em receber honras, mas em merecê-las.
(Aristóteles)

Resumo

Atualmente, cerca de 30% do tempo de uma consulta médica é dedicado ao preenchimento de formulários e ao registro de informações clínicas. O ESCRIBAS tem como objetivo reduzir esse percentual para entre 5% e 8% por meio de um software capaz de capturar o áudio da consulta e preencher automaticamente dados relevantes — como peso, altura, sintomas relatados, medicação diária, entre outros. A implementação da solução demonstrou uma redução de aproximadamente 7% no tempo gasto com essas tarefas, evidenciando resultados positivos e viáveis.

Palavras-chave: inteligência artificial; reconhecimento de fala; prontuário eletrônico; LGPD; automação clínica.

Resumo

Approximately 30% of the time during a medical consultation is spent on completing forms and maintaining clinical records. The ESCRIBAS project aims to reduce this percentage to between 5% and 8% through software capable of capturing consultation audio and automatically filling in relevant data—such as weight, height, reported symptoms, daily medications, among others. The implementation of the solution showed an approximate 7% reduction in time spent on these tasks, demonstrating positive and feasible results.

Keywords: artificial intelligence; speech recognition; electronic medical record; data protection; healthcare automation.

Sumário

Agradecimentos	3
1 Introdução	9
2 Projeto ESCRIBAS	11
3 LGPD – Lei Geral de Proteção de Dados	13
4 Objetivo Geral	14
4.0.1 Objetivos Específicos	14
5 Referencial Teórico	15
5.0.1 Inteligência Artificial	15
5.0.1.1 Modelos de IA e Transcrição de Áudio	16
5.0.1.2 Whisper	17
5.0.1.2.1 1. Extração de Características: STFT e Log-Mel Spectrogram	17
5.0.1.2.2 2. Codificação com Transformer Encoder	18
5.0.1.2.3 3. Decodificação Autoregressiva	18
5.0.1.2.4 4. Implementação no Projeto	18
5.0.1.3 SpeechRecognition	20
5.0.2 Tratamento de Áudio	20
5.0.2.1 PyAudio	20
5.0.3 Microfones de Carbono	21
5.0.3.1 Descrição Matemática	22
5.0.4 Microfones Condensadores	23
5.0.4.1 Descrição Matemática	23
5.0.5 Microfones MEMS	23
5.0.5.1 Modelagem Matemática	24
5.0.5.2 Variação da Capacitância	24
5.0.5.3 Energia Mecânica da Membrana	24
5.0.5.4 Exemplo Numérico	25
6 Metodologia	26
7 Pesquisa Bibliográfica	28
8 Seleção Tecnológica	30
9 Cronograma	32
 Referências	 35

Lista de ilustrações

Figura 1 – Estrutura Whisper	17
Figura 2 – Fluxo de Implementação (Imagem Gerada por IA).	20
Figura 3 – Estrutura do microfone de carbono (Imagem Gerada por IA).	21
Figura 4 – Fluxo de funcionamento do microfone de carbono.	22
Figura 5 – Esquema de funcionamento de um microfone condensador.	23
Figura 6 – Gráfico de Gantt do projeto <i>ESCRIBAS</i>	34

Lista de tabelas

Tabela 1 – Indicadores Comparativos dos Modelos Whisper	26
Tabela 2 – Cronograma de atividades do projeto <i>ESCRIBAS</i>	32

1 Introdução

O sistema de saúde brasileiro enfrenta desafios estruturais profundos, que afetam diretamente a qualidade, eficiência e universalidade do atendimento médico prestado à população. Longas filas para consultas, diagnósticos e cirurgias, somadas à escassez de recursos humanos e infraestrutura inadequada, compõem um cenário preocupante. Dados do Conselho Federal de Medicina apontam que cerca de 30% da população aguarda atualmente por atendimento no Sistema Único de Saúde (SUS), revelando um quadro crônico de sobrecarga [Medicina 2019].

Além da demanda reprimida, a reduzida duração das consultas médicas representa outro entrave à qualidade do atendimento. Estudos revelam que o tempo médio de consulta nas unidades de atenção básica à saúde no Brasil varia entre 12 e 15 minutos [Tomasi, Facchini e Piccini 2017], comprometendo a escuta ativa, a construção de vínculo com o paciente e a acurácia diagnóstica. Essa limitação também afeta negativamente a eficácia terapêutica e aumenta a possibilidade de erros clínicos [Silva e colaboradores 2020, Oliveira e Lima 2022].

Boa parte desse tempo limitado é consumida com tarefas burocráticas, como o preenchimento de prontuários médicos, prescrições e registros de exames. Estima-se que até 30% do tempo de um atendimento seja destinado exclusivamente à documentação clínica [Ferreira e outros 2023]. Essa sobrecarga administrativa se contrapõe à crescente complexidade das demandas de saúde e à expectativa da população por um atendimento mais humanizado, preciso e resolutivo.

Esses problemas não são recentes e encontram raízes históricas no processo de transformação epidemiológica da sociedade brasileira. A **Teoria da Transição Epidemiológica**, proposta por Abdel R. Omran na década de 1970, oferece uma estrutura teórica robusta para compreender a evolução dos padrões de saúde e doença nas sociedades modernas. Essa transição representa a passagem de um cenário predominado por doenças infecciosas e parasitárias para um perfil marcado por enfermidades crônicas, degenerativas e causas externas, como acidentes e violência [Omran 1971].

No Brasil, esse processo ganhou intensidade a partir da segunda metade do século XX, impulsionado por fatores como urbanização acelerada, mudanças nos hábitos alimentares e envelhecimento populacional. Hoje, o país convive com um triplo desafio epidemiológico: o controle de doenças infecciosas, a prevenção e tratamento de doenças crônicas não transmissíveis e o enfrentamento das causas externas [Saúde 2021].

Frente a esse contexto desafiador, a adoção de tecnologias emergentes, como a inteligência artificial (IA) e o reconhecimento de fala, apresenta-se como uma estratégia promissora para qualificar os serviços de saúde. Essas ferramentas permitem a automação de processos repetitivos e a análise estruturada de grandes volumes de dados clínicos,

liberando os profissionais para uma atuação mais estratégica e focada no cuidado direto ao paciente.

O presente trabalho se insere nesse cenário como uma proposta concreta de inovação tecnológica. O projeto **ESCRIBAS** visa desenvolver um sistema automatizado de transcrição de prontuários médicos, utilizando modelos de inteligência artificial baseados em aprendizado profundo. Ao captar e processar o áudio das consultas, o sistema busca reduzir o tempo dedicado à burocracia, aumentar a precisão dos registros e assegurar a conformidade com a Lei Geral de Proteção de Dados (LGPD), ao mesmo tempo em que promove um atendimento mais ágil, seguro e centrado no paciente.

2 Projeto ESCRIBAS

Diante da sobrecarga nos serviços de saúde, torna-se imperativo adotar soluções tecnológicas que otimizem o tempo dos profissionais da área médica, permitindo maior dedicação à escuta qualificada dos pacientes e à elaboração de diagnósticos mais precisos. Estimativas indicam que até 30% do tempo total de uma consulta é consumido com a documentação clínica, prescrição de medicamentos e preenchimento de sistemas informatizados [Souza e Rocha 2021, Ferreira e outros 2023].

É nesse cenário que se insere o projeto **ESCRIBAS**, uma proposta inovadora que visa automatizar o processo de registro clínico por meio do reconhecimento de fala e da inteligência artificial (IA). O software tem como principal finalidade captar, transcrever e estruturar o conteúdo das consultas médicas, preenchendo de forma automatizada o prontuário eletrônico, sem interferir na análise clínica ou sugerir tratamentos, condutas ou prescrições.

O funcionamento do ESCRIBAS inicia-se com o acionamento do sistema por parte do profissional de saúde. Antes de iniciar o atendimento, o médico ativa o módulo de gravação, autorizando o sistema a captar o áudio da consulta. Utilizando microfones direcionais de alta sensibilidade, o sistema registra o diálogo entre médico e paciente, enviando-o para um módulo de transcrição baseado em modelos de aprendizado profundo.

Após a captação, o áudio é segmentado em intervalos curtos e processado por um modelo de reconhecimento automático de fala (ASR), que converte os sinais acústicos em texto. A seguir, técnicas de Processamento de Linguagem Natural (NLP) são aplicadas para estruturar as informações extraídas, classificando-as de acordo com categorias clínicas relevantes, tais como: identificação do paciente, histórico médico, queixas principais, sintomas relatados, altura, peso e uso contínuo de medicamentos.

O projeto foi cuidadosamente desenhado para garantir a neutralidade clínica e a segurança jurídica. O ESCRIBAS não realiza nenhum tipo de inferência diagnóstica, sugestão terapêutica ou prescrição automatizada. Seu papel se limita à transcrição fiel e estruturada das informações ditas durante a consulta, cabendo exclusivamente ao profissional de saúde a análise e a tomada de decisões clínicas.

O sistema conta com integração via APIs com prontuários eletrônicos (PEP), respeitando os padrões estabelecidos pela saúde suplementar e pública. Os dados transcritos podem ser armazenados tanto localmente quanto em servidores em nuvem, dependendo da infraestrutura da instituição usuária. Todos os procedimentos estão alinhados à Lei Geral de Proteção de Dados (LGPD), com uso de criptografia, controle de acesso e consentimento informado dos pacientes.

Além de aumentar a produtividade e padronizar os registros clínicos, o ESCRIBAS contribui para a valorização do tempo do médico e a humanização do atendimento, ao

permitir que a atenção se concentre no paciente, e não na tela do computador.

3 LGPD – Lei Geral de Proteção de Dados

A Lei Geral de Proteção de Dados (Lei nº 13.709/2018), vigente desde setembro de 2020, estabelece diretrizes rigorosas para proteger as informações pessoais dos cidadãos brasileiros. Essa legislação detalha os conceitos de dados pessoais e dados sensíveis, enfatizando a necessidade de garantir privacidade, segurança e transparência na coleta, armazenamento, processamento e compartilhamento de informações.

Nesse contexto, o projeto ESCRIBAS adota práticas rigorosas de segurança e privacidade em conformidade com as exigências da LGPD. Dado o caráter sensível das informações envolvidas em contextos médicos, o projeto implementa uma série de medidas específicas para proteger os dados coletados. Entre os principais tipos de informações processadas pelo ESCRIBAS destacam-se:

- **Dados biométricos de voz:** captados durante a interação médico-paciente, utilizados para identificação precisa dos indivíduos;
- **Dados sensíveis de saúde:** incluem sintomas relatados, diagnósticos médicos, prescrições de medicamentos e históricos clínicos detalhados, conforme definido no Art. 5º, inciso II da LGPD;
- **Dados identificáveis:** nome completo, número do prontuário, CPF, registro médico (CRM) e quaisquer outros elementos que permitam identificar direta ou indiretamente os indivíduos.

Essas informações requerem consentimento explícito e inequívoco por parte dos titulares, em conformidade com o Art. 11, inciso I da LGPD. Assim, o projeto ESCRIBAS assegura a obtenção do consentimento por meio de mecanismos claros e transparentes, informando detalhadamente sobre o uso dos dados e oferecendo controle aos usuários sobre suas informações pessoais.

Adicionalmente, para garantir a segurança dos dados, o projeto adota técnicas avançadas como criptografia de ponta a ponta, controle rigoroso de acesso por meio de autenticação multifatorial e armazenamento seguro, seja em servidores locais ou em nuvem, com monitoramento constante para prevenir e detectar possíveis incidentes de segurança. Essas práticas são continuamente revisadas e atualizadas para atender às melhores práticas internacionais e garantir total conformidade com a LGPD, fortalecendo a confiança e segurança dos usuários e das instituições de saúde parceiras.

4 Objetivo Geral

A implementação técnica do protótipo do projeto **ESCRIBAS** busca desenvolver um sistema capaz de realizar a transcrição automática do áudio captado durante consultas médicas, com foco na automação do preenchimento de prontuários clínicos e na extração de informações relevantes que auxiliem o cotidiano dos profissionais da saúde.

4.0.1 Objetivos Específicos

- Captar o áudio da consulta por meio de microfones conectados ao sistema, com o auxílio da biblioteca PyAudio, permitindo a gravação e manipulação direta dos sinais acústicos [PyAudio Documentation];
- Realizar o pré-processamento dos áudios, segmentando-os e convertendo-os em espectrogramas de log-mel, além de efetuar a transcrição automática utilizando o modelo Whisper;
- Estruturar os dados transcritos por meio de técnicas de Processamento de Linguagem Natural (NLP), visando à identificação de informações clínicas relevantes;
- Integrar as informações extraídas com o preenchimento automatizado do prontuário médico.

5 Referencial Teórico

O projeto ESCRIBAS é uma solução tecnológica inovadora voltada para o auxílio de médicos em suas consultas, com o objetivo principal de otimizar e modernizar o atendimento clínico por meio da automação de processos. O software foi idealizado com foco na praticidade e na eficiência, utilizando a tecnologia como meio para reduzir o tempo gasto com tarefas administrativas, como o preenchimento de prontuários médicos. Seu funcionamento baseia-se na captação do áudio das consultas por meio de microfones, registrando com fidelidade as informações transmitidas pelo paciente ao profissional de saúde. Essas informações são então processadas por modelos de transcrição e inteligência artificial, que convertem o áudio em texto estruturado, identificam os dados relevantes e preenchem automaticamente os campos correspondentes no prontuário médico.

Para que esse processo seja realizado de maneira eficaz, o projeto ESCRIBAS incorpora um ecossistema de ferramentas tecnológicas. A linguagem de programação Python é utilizada como base para o desenvolvimento do Back-End do sistema, dada sua robustez e ampla gama de bibliotecas voltadas para ciência de dados e inteligência artificial. Modelos avançados de transcrição de áudio são empregados para converter a fala em texto, possibilitando a extração, análise e categorização de informações clínicas. Esses dados são posteriormente armazenados em um banco de dados, garantindo a integridade e a disponibilidade das informações. Uma camada adicional de inteligência artificial generativa é aplicada para identificar automaticamente dados como peso, altura, sintomas relatados e possíveis diagnósticos, contribuindo significativamente para a qualidade e agilidade do atendimento médico.

Após essa contextualização sobre a proposta operacional e tecnológica do projeto ESCRIBAS, é imprescindível aprofundar a análise dos componentes técnicos que compõem sua arquitetura. Considerando os desafios enfrentados pelo sistema de saúde brasileiro — como a sobrecarga de profissionais, a lentidão nos atendimentos e a crescente demanda por qualidade e precisão nos registros clínicos —, bem como os requisitos impostos pela Lei Geral de Proteção de Dados (LGPD), torna-se essencial compreender as soluções adotadas em termos de inteligência artificial, captação e tratamento de áudio e organização automatizada das informações.

5.0.1 Inteligência Artificial

A Inteligência Artificial (IA) é um campo interdisciplinar da ciência da computação dedicado à criação de sistemas capazes de simular comportamentos inteligentes. Essas tarefas incluem aprendizado contínuo, reconhecimento e interpretação de padrões complexos, raciocínio lógico, percepção sensorial, compreensão de linguagem natural e tomada autô-

noma de decisões. Avanços recentes em aprendizado de máquina — especialmente em aprendizado profundo (deep learning) — impulsionaram progressos marcantes em visão computacional, reconhecimento de fala e processamento de linguagem natural.

No contexto específico do projeto ESCRIBAS, destaca-se o uso de modelos baseados na arquitetura Transformer, como GPT, Gemini e DeepSeek. Esses modelos, treinados em larga escala, são capazes de interpretar contextos complexos e gerar texto coerente, permitindo a transcrição e a estruturação automatizada de diálogos médicos.

5.0.1.1 Modelos de IA e Transcrição de Áudio

O reconhecimento automático de fala (ASR – *Automatic Speech Recognition*) é o processo computacional de converter sinais acústicos da fala humana em texto. Esse campo é um dos mais antigos da inteligência artificial aplicada, remontando à década de 1950, quando os primeiros sistemas eram capazes apenas de reconhecer dígitos isolados, com vocabulários extremamente limitados [Juang e Rabiner 2004].

A evolução do ASR passou por diversas gerações de modelos e paradigmas. Inicialmente, os sistemas baseavam-se em técnicas simples de correlação e *template matching*, que tentavam comparar o sinal de entrada com padrões pré-gravados. No entanto, essas abordagens eram altamente sensíveis a variações na pronúncia, tom e ruído.

A partir da década de 1970, os **Modelos Ocultos de Markov** (HMMs) passaram a dominar a área. Os HMMs permitem representar o comportamento estocástico da fala como uma sequência de estados ocultos que geram observações acústicas de forma probabilística. Esse modelo é especialmente adequado à natureza temporal da fala, pois considera dependências sequenciais e pode ser treinado por meio do algoritmo de Baum-Welch (uma forma do algoritmo EM – *Expectation-Maximization*) [Rabiner 1989].

Com os avanços na capacidade computacional e no volume de dados disponíveis, os HMMs foram combinados a redes neurais artificiais (ANNs), resultando nos chamados sistemas híbridos HMM-DNN (*Deep Neural Network*). Essa fusão aumentou significativamente a precisão do ASR, ao permitir a modelagem mais robusta das características acústicas.

A partir de 2017, a introdução dos **Transformers** — arquiteturas baseadas inteiramente em mecanismos de atenção — revolucionou o campo. Modelos como o Whisper, o wav2vec 2.0 e o Conformer substituem completamente as HMMs por estruturas de atenção contextualizada, capazes de aprender representações de longo alcance sem a necessidade de segmentações manuais [Radford e outros 2022, Baevski et al. 2020].

Esses modelos operam diretamente sobre espectrogramas ou até mesmo sinais de áudio brutos, utilizando camadas de codificadores (encoders) e, em alguns casos, decodificadores (decoders) autoregressivos, como no caso do Whisper. Eles são treinados com grandes volumes de dados de áudio transcrito e se beneficiam de técnicas como *self-supervised learning*, *data augmentation* e *transfer learning*.

Além disso, os sistemas modernos de ASR passaram a incorporar mecanismos de normalização de ruído, adaptação ao locutor e segmentação automática por locutor (*diarization*), permitindo transcrições mais precisas mesmo em ambientes complexos com múltiplos participantes e interferência acústica.

A adoção desses modelos de transcrição no contexto clínico, como no projeto ESCRIBAS, permite não apenas um ganho de velocidade e precisão, mas também uma redução significativa da carga cognitiva sobre os profissionais, contribuindo para registros médicos mais completos e fidedignos.

5.0.1.2 Whisper

O Whisper, da OpenAI, emprega uma arquitetura Transformer para transcrição de áudio. A entrada de áudio é dividida em segmentos de 30 s, convertida em espectrogramas de log-mel e processada por blocos de encoder-decoder. A saída é gerada de forma autoregressiva.




Figura 1 – Estrutura Whisper

5.0.1.2.1 1. Extração de Características: STFT e Log-Mel Spectrogram

$$\text{STFT}\{x(t)\}(m, \omega) = \sum_{n=-\infty}^{+\infty} x[n]w[n-m]e^{-j\omega n} \quad (5.1)$$

Onde: - $x[n]$ é o sinal de entrada discretizado, - $w[n]$ é a janela de análise (geralmente Hamming ou Hann), - m é o índice de tempo, - ω é a frequência angular.

5.0.1.2.2 2. Codificação com Transformer Encoder

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5.2)$$

Onde: - Q, K, V são as matrizes de consulta, chave e valor obtidas por projeções lineares de E , - d_k é a dimensão das chaves.

5.0.1.2.3 3. Decodificação Autoregressiva

A saída codificada é passada ao decoder, que utiliza atenção cruzada (cross-attention) entre a entrada codificada e os tokens gerados até então. O processo de decodificação é autoregressivo, isto é, cada token depende dos anteriores. A distribuição de probabilidade para o próximo token é calculada via softmax:

$$P(y_t|y_{<t}, E) = \text{softmax}(W_o h_t + b) \quad (5.3)$$

Onde: - y_t é a palavra (ou token) prevista no instante de tempo t ; - $y_{<t}$ representa todas as palavras anteriores ao instante t ; - E é a representação codificada da entrada (por exemplo, o áudio processado pelo encoder); - h_t é o vetor de estado oculto (hidden state) do decoder no tempo t ; - W_o é a matriz de pesos da camada de saída; - b é o vetor de viés (bias); - softmax transforma a saída linear em uma distribuição de probabilidade sobre o vocabulário.

O texto final é obtido amostrando ou selecionando os tokens com maior probabilidade a cada passo do decoder.

5.0.1.2.4 4. Implementação no Projeto

No projeto **ESCRIBAS**, optou-se pela utilização da versão *small* do modelo Whisper, desenvolvida pela OpenAI. Essa versão foi escolhida por oferecer um bom equilíbrio entre desempenho computacional e precisão de transcrição, apresentando significativa redução de ruídos nos testes realizados. Observou-se uma diminuição de **98,15%** nas ocorrências de transcrições com ruído, em comparação com as versões *tiny* e *base* do modelo. Além disso, a versão *small* mostrou-se viável para execução local em computadores equipados com GPU de desempenho intermediário-alto, garantindo a autonomia do sistema sem a necessidade de processamento em nuvem.

O fluxo de funcionamento inicia-se com a captação do áudio da consulta médica, realizada por microfones direcionais. O sinal de áudio bruto é, então, convertido em um

espectrograma de log-mel — uma representação visual das frequências do som ao longo do tempo, que preserva as características acústicas relevantes para a transcrição de fala.

Essa conversão é realizada utilizando duas bibliotecas fundamentais no ecossistema Python: a `numpy`, por meio da função `numpy.fft` para aplicação da Transformada Rápida de Fourier (FFT), e a `torchaudio`, que facilita a manipulação de sinais de áudio e a geração do espectrograma log-mel. A FFT é responsável por transformar o sinal do domínio do tempo para o domínio da frequência, base essencial para a construção do espectrograma.

Após a extração dessas características acústicas, o espectrograma gerado é processado pelo encoder do Whisper, que transforma as informações visuais do áudio em representações vetoriais de alta dimensionalidade. Essas representações são, então, utilizadas pelo decoder, que gera o texto correspondente de forma autoregressiva — ou seja, palavra por palavra, com base nas anteriores.

A etapa de decodificação é realizada com o auxílio da função `torch.nn.functional.softmax`, que aplica uma normalização probabilística sobre a saída do modelo, transformando os logits em probabilidades associadas a cada token do vocabulário. O token com maior probabilidade é então selecionado como a próxima palavra da transcrição.

Esse processo completo, desde a captação até a geração do texto final, ocorre em tempo quase real, permitindo que o prontuário médico seja preenchido automaticamente enquanto a consulta acontece. Além de aumentar a produtividade, essa abordagem mantém a privacidade e segurança dos dados, já que todo o processamento ocorre localmente, em conformidade com a LGPD.




Figura 2 – Fluxo de Implementação (Imagem Gerada por IA).

5.0.1.3 SpeechRecognition

A biblioteca SpeechRecognition integra diversas APIs (Google, Sphinx, IBM, Whisper), simplificando o código de captura e reconhecimento de áudio. Aliada ao PyAudio, oferece fluxo de áudio em tempo real, robusto e flexível.

5.0.2 Tratamento de Áudio

5.0.2.1 PyAudio

Essa biblioteca, tem como foco facilitar o fluxo de manipulação de entradas de áudio em Python, com uma interface simples para trabalhar com a gravação e reprodução desses

áudios. Portanto uso do Pyaudio no ESCRIBAS é fundamental para capturar o áudio da conversa entre médico e paciente, sendo o ponto de partida para todo o processo de automação do preenchimento do prontuário. [11] Seu funcionamento ocorre por meio de uma conexão com o sistema de áudio do computador, feita pela biblioteca PortAudio, que atua como uma camada de abstração entre a aplicação Python e as APIs nativas de áudio do sistema operacional, sendo assim quando uma instância da Pyaudio é criada, e o fluxo de áudio é aberto por meio do método “open()” contido nessa biblioteca, ela configura os parâmetros desejados e estabelece a comunicação com os dispositivos de áudio disponíveis. A PortAudio, interage com as APIs nativas de áudio, como Core Audio no macOS, WASAPI no Windows e ALSA no Linux, para realizar a captura e reprodução de áudio. [PyAudio Documentation].

5.0.3 Microfones de Carbono

Os primeiros microfones comercializados foram os de carbono, patenteados por Thomas Edison e Emile Berliner em 1877. Esses modelos possuíam uma estrutura simples, composta por um diafragma conectado a uma haste de metal, que variava a resistência dos grãos de carbono em resposta às ondas sonoras.

Devido à sua simplicidade, durabilidade e baixo custo, o microfone de carbono tornou-se amplamente utilizado nos primeiros sistemas telefônicos, consolidando-se como um item básico por mais de um século.

O princípio de funcionamento consistia em grãos de carbono inseridos entre dois eletrodos. Ao captar a fala, as vibrações sonoras moviam o diafragma, que pressionava os grãos, alterando sua resistência elétrica. Assim, a corrente variava conforme as ondas sonoras, convertendo som em sinal elétrico.




Figura 3 – Estrutura do microfone de carbono (Imagem Gerada por IA).

5.0.3.1 Descrição Matemática

A corrente elétrica varia conforme a resistência, obedecendo à Lei de Ohm:

$$I = \frac{V}{R} \quad (5.4)$$

Onde:

- I é a corrente elétrica (A);
- V é a tensão aplicada (V);
- R é a resistência elétrica (Ω).




Figura 4 – Fluxo de funcionamento do microfone de carbono.

5.0.4 Microfones Condensadores

Os microfones condensadores surgiram no início do século XX, oferecendo melhor resposta de frequência e menor distorção comparados aos de carbono. Seu funcionamento baseia-se na variação da capacitância para converter som em sinal elétrico.

Um microfone condensador possui duas placas metálicas muito próximas: uma membrana flexível e uma placa fixa. A vibração sonora altera a distância entre as placas, modificando a capacitância.




Figura 5 – Esquema de funcionamento de um microfone condensador.

5.0.4.1 Descrição Matemática

$$C = \varepsilon \frac{A}{d} \quad (5.5)$$

Onde:

- C é a capacitância (F);
- ε é a permissividade do meio;
- A é a área das placas (m^2);
- d é a distância entre as placas (m).

5.0.5 Microfones MEMS

O avanço dos **Sistemas Microeletromecânicos** (MEMS) permitiu o surgimento de microfones miniaturizados, robustos e eficientes, amplamente utilizados em dispositivos portáteis.

Esses microfones utilizam uma membrana móvel e uma placa fixa, tal como os condensadores, mas com dimensões microscópicas.

- Placa fixa;
- Membrana móvel;
- Circuito eletrônico integrado (amplificador e conversor A/D).

5.0.5.1 Modelagem Matemática

A pressão sonora incidente é modelada como:

$$p(t) = p_0 \sin(\omega t) \quad (5.6)$$

Onde:

- p_0 é a amplitude da pressão sonora;
- $\omega = 2\pi f$ é a frequência angular;
- f é a frequência da onda sonora (Hz).

A equação do movimento da membrana é:

$$m \frac{d^2 x(t)}{dt^2} + kx(t) = UM \cdot p(t) \quad (5.7)$$

Onde:

- m é a massa da membrana;
- k é a constante elástica;
- UM é a área útil da membrana;
- $x(t)$ é o deslocamento no tempo.

5.0.5.2 Variação da Capacitância

Com o deslocamento $x(t)$ da membrana, a capacitância $C(t)$ torna-se:

$$C(t) = \frac{\varepsilon A}{d_0 + x(t)} \quad (5.8)$$

A taxa de variação é:

$$\frac{dC(t)}{dt} = -\varepsilon A \frac{1}{(d_0 + x(t))^2} \frac{dx(t)}{dt} \quad (5.9)$$

5.0.5.3 Energia Mecânica da Membrana

A energia total E_{mec} é a soma da energia cinética E_{cin} e da energia potencial elástica E_{pot} :

Energia Cinética

$$E_{cin}(t) = \frac{1}{2}m \left(\frac{dx(t)}{dt} \right)^2 \quad (5.10)$$

Energia Potencial Elástica

$$E_{pot}(t) = \frac{1}{2}kx(t)^2 \quad (5.11)$$

Energia Mecânica Total

$$E_{mec}(t) = E_{cin}(t) + E_{pot}(t) \quad (5.12)$$

5.0.5.4 Exemplo Numérico

Dado:

- $m = 1 \mu g = 1 \times 10^{-9} kg$;
- $k = 10 N/m$;
- $x_{max} = 100 nm = 1 \times 10^{-7} m$;
- $v_{max} = 0,01 m/s$.

Energia cinética:

$$E_{cin} = \frac{1}{2} \times 1 \times 10^{-9} \times (0,01)^2 = 5 \times 10^{-14} J \quad (5.13)$$

Energia potencial:

$$E_{pot} = \frac{1}{2} \times 10 \times (1 \times 10^{-7})^2 = 5 \times 10^{-14} J \quad (5.14)$$

Energia total:

$$E_{mec} = E_{cin} + E_{pot} = 1 \times 10^{-13} J \quad (5.15)$$

Essa energia é extremamente pequena, o que demonstra que o objetivo dos microfones MEMS é a detecção precisa de som, e não a geração de energia elétrica.

6 Metodologia

Este trabalho adotou uma metodologia aplicada com abordagem qualitativa e quantitativa, estruturada em etapas sequenciais e complementares. Primeiramente, foi realizada uma pesquisa bibliográfica abrangente, abordando temas fundamentais como Inteligência Artificial (IA), [Juang e Rabiner 2004], Processamento de Linguagem Natural (NLP), reconhecimento automático de fala (ASR) e proteção de dados pessoais conforme determina a Lei Geral de Proteção de Dados (LGPD)[Federal 2018]. As fontes consultadas incluíram artigos científicos, relatórios técnicos, livros e documentos oficiais relevantes para embasar teoricamente a pesquisa.

Este estudo utiliza uma metodologia aplicada com enfoque experimental, estruturada em quatro etapas detalhadas: pesquisa bibliográfica, seleção tecnológica, desenvolvimento técnico do protótipo utilizando o modelo Whisper da OpenAI, e avaliação prática e análise dos resultados.

O projeto ESCRIBAS nasceu com o objetivo de solucionar uma questão crítica enfrentada por profissionais da saúde: o tempo excessivo gasto em tarefas administrativas, como o preenchimento de prontuários médicos. A abordagem escolhida foi utilizar tecnologias de reconhecimento automático de fala (ASR - Automatic Speech Recognition) para capturar e transcrever automaticamente o diálogo entre médico e paciente, estruturando essas informações diretamente nos sistemas eletrônicos das clínicas e hospitais.

No início do projeto, foram pesquisadas diversas ferramentas para a realização da tarefa de transcrição. Dentre elas, o modelo Whisper, desenvolvido pela OpenAI, destacou-se por sua capacidade técnica e resultados consistentes. A fim de selecionar a solução mais adequada, foram realizados testes considerando aspectos como precisão da transcrição, resistência a ruídos externos e tempo necessário para o processamento dos áudios.

O Whisper foi testado localmente em suas versões *Tiny*, *Base*, *Small* e *Medium*, sendo essa última limitada por seu custo computacional mais elevado. Embora tenha apresentado resultados promissores em termos de precisão — especialmente nas versões mais robustas —, cada variante demonstrou comportamentos distintos. Todos os testes foram realizados em contextos de transcrição em tempo real, exigindo resposta rápida por parte do software. Os indicadores comparativos obtidos estão apresentados na Tabela 1.

Tabela 1 – Indicadores Comparativos dos Modelos Whisper

Modelo	Taxa de Sucesso	Total de Ruído	Média de Ruído
Whisper Tiny	0,6675	1032	344,0
Whisper Base	0,65625	807	269,0
Whisper Small	0,73	11	5,5

Com base nos resultados da Tabela 1, observa-se uma redução significativa na suscetibilidade a ruídos conforme se avançam as versões do modelo. Cada teste consistiu na transcrição de frases simples, como “Boa tarde” e “Tudo bem?”. O modelo *Small*, em especial, demonstrou uma drástica redução nos ruídos e apresentou a maior taxa de sucesso na reconstrução correta das frases de teste.

Portanto, considerando os resultados obtidos, o Whisper *Small* foi selecionado como a solução oficial para o desenvolvimento e implementação do projeto **ESCRIBAS**. Essa escolha visa garantir a confiabilidade operacional necessária para apoiar os profissionais da saúde em sua rotina diária, permitindo maior atenção ao paciente e reduzindo o tempo dedicado a atividades administrativas repetitivas.

7 Pesquisa Bibliográfica

A etapa inicial do desenvolvimento do projeto ESCRIBAS consistiu em uma revisão sistemática da literatura acadêmica e técnica, com o objetivo de mapear as principais abordagens, desafios e avanços no campo da Inteligência Artificial (IA), especialmente nos domínios do Processamento de Linguagem Natural (NLP – *Natural Language Processing*) e do Reconhecimento Automático de Fala (ASR – *Automatic Speech Recognition*).

A pesquisa bibliográfica abrangeu artigos científicos, relatórios técnicos, teses, repositórios oficiais de código e white papers publicados por centros de pesquisa de referência internacional, como OpenAI, Google Research e instituições acadêmicas. O foco principal foi compreender a evolução dos modelos de transcrição de fala, desde as primeiras técnicas baseadas em regras até os atuais modelos baseados em redes neurais profundas.

Modelos baseados em **Hidden Markov Models** (HMMs), amplamente utilizados nas décadas de 1980 e 1990, foram analisados como parte do arcabouço histórico do ASR, tendo sido fundamentais para os primeiros avanços na modelagem estatística da fala [Rabiner 1989, Juang e Rabiner 2004]. No entanto, a pesquisa também evidenciou suas limitações, como a suposição de independência entre observações e a dificuldade de modelar dependências de longo prazo.

Com o advento das redes neurais profundas (*Deep Neural Networks – DNNs*), especialmente após 2012, os modelos híbridos HMM-DNN começaram a apresentar melhorias significativas de desempenho. Essa evolução culminou no surgimento de arquiteturas fim-a-fim baseadas em **Transformers**, que eliminaram a necessidade de pipelines complexos e permitiram o treinamento direto de entrada para saída em tarefas de transcrição [Vaswani et al. 2017, Baevski et al. 2020].

Entre os modelos mais recentes, o **Whisper**, desenvolvido pela OpenAI, destacou-se na literatura pela sua robustez frente a ruídos, sua capacidade multilinguística e pelo uso de aprendizado fraco supervisionado em larga escala. Foram analisadas tanto a publicação técnica oficial do modelo [Radford e outros 2022], quanto estudos independentes de benchmarking e validação do desempenho em ambientes reais, como os de saúde, educação e atendimento ao cliente [Goyal, Gupta e Soni 2022].

Adicionalmente, a revisão incluiu tópicos fundamentais sobre o funcionamento matemático da transcrição de fala, como a Transformada de Fourier de Curto Prazo (STFT), espectrogramas log-mel, atenção escalada e decodificação autoregressiva, todos componentes-chave no pipeline de transcrição do Whisper. Também foram estudadas as implicações éticas e legais do uso de IA em contextos sensíveis, como a saúde, com ênfase na conformidade com a Lei Geral de Proteção de Dados (LGPD).

Assim, a pesquisa bibliográfica forneceu o embasamento teórico necessário para a definição da arquitetura do sistema, a seleção do modelo de transcrição e o planejamento

dos testes e validações subsequentes.

8 Seleção Tecnológica

Com base na revisão sistemática da literatura e na análise de ferramentas disponíveis no estado da arte, o modelo **Whisper**, desenvolvido pela OpenAI, foi selecionado como núcleo tecnológico para o projeto ESCRIBAS. Essa escolha se deve a um conjunto de fatores técnicos e operacionais que tornam o modelo particularmente adequado para ambientes clínicos, como consultórios médicos e centros de saúde.

O Whisper é uma rede neural de transcrição de áudio baseada na arquitetura Transformer, a mesma que fundamenta modelos de linguagem como o GPT. A principal inovação do Whisper reside no seu treinamento em larga escala utilizando *aprendizado fraco supervisionado* (*weakly-supervised learning*). Para isso, a OpenAI utilizou cerca de 680 mil horas de dados de áudio multilíngue, pareados com transcrições, permitindo ao modelo aprender padrões fonéticos, semânticos e contextuais de forma robusta [Radford e outros 2022].

Diferentemente de abordagens anteriores que dependiam de pipelines com múltiplos módulos — como separação entre extração de características, alinhamento fonético e reconhecimento acústico — o Whisper adota uma abordagem fim-a-fim (*end-to-end*), integrando todas essas etapas em um único modelo neural. Isso reduz significativamente a complexidade do sistema, melhora a generalização em diferentes contextos acústicos e torna a manutenção e integração mais acessíveis para projetos independentes como o ESCRIBAS.

Outro diferencial do Whisper é sua capacidade de lidar com múltiplos idiomas, sotaques variados, e ambientes com ruído moderado, graças ao seu processo de pré-treinamento multimodal e multilinguístico. Além disso, o modelo foi disponibilizado em cinco versões distintas — Tiny, Base, Small, Medium e Large — que variam em número de parâmetros, camadas e custo computacional. Após testes preliminares, optou-se pela versão *Small*, que apresenta um bom equilíbrio entre precisão de transcrição e viabilidade operacional em dispositivos locais com GPU [Goyal, Gupta e Soni 2022].

Essa versão é capaz de realizar transcrição com tempos de resposta aceitáveis, mesmo em tempo quase real, o que é essencial para o uso em consultórios médicos. A compatibilidade do Whisper com bibliotecas populares de aprendizado profundo, como PyTorch, também favorece sua integração com APIs, bancos de dados clínicos e ferramentas de NLP para estruturação semântica dos dados extraídos.

Portanto, a escolha do Whisper se justifica não apenas pelo seu desempenho técnico superior, mas também pela sua adaptabilidade a diferentes cenários clínicos e pela facilidade de implementação em soluções de código aberto, como a proposta no projeto ESCRIBAS.

A validação prática do sistema foi conduzida em ambiente clínico real, utilizando

consultas médicas simuladas e reais para avaliação do desempenho. O objetivo desta fase foi analisar quantitativamente e qualitativamente a eficácia operacional do modelo Whisper em termos de precisão das transcrições, tempo médio de processamento, robustez a ruídos externos e qualidade da informação extraída para o preenchimento automático dos prontuários médicos.

Foram coletados dados comparativos sobre o tempo gasto pelos profissionais médicos na documentação clínica antes e após a utilização do sistema ESCRIBAS. Além disso, entrevistas estruturadas e questionários padronizados foram aplicados aos médicos participantes para captar percepções qualitativas sobre o impacto da tecnologia na rotina clínica.

Os resultados obtidos foram submetidos a uma análise detalhada, permitindo avaliar claramente os benefícios técnicos e operacionais proporcionados pela utilização exclusiva do modelo Whisper, confirmando sua viabilidade técnica e prática no contexto da automação da documentação clínica.

9 Cronograma

O cronograma do projeto **ESCRIBAS** foi elaborado com base nas principais entregas ao longo do desenvolvimento, desde a fase inicial de levantamento de ideias até a entrega da documentação referente à primeira etapa do projeto. A Tabela 2 apresenta as atividades realizadas, seus respectivos responsáveis e os períodos de execução, todos organizados por fases.

Tabela 2 – Cronograma de atividades do projeto *ESCRIBAS*

Atividade	Responsáveis	Início	Término
Fase 1 – Planejamento e Ideação			
Entendimento da Matéria	Enzo e Saymon	04/02/2025	06/02/2025
Levantamento de Ideias	Enzo e Saymon	06/02/2025	16/02/2025
Ideias v1	Enzo	06/02/2025	16/02/2025
Discussão Ideias v1	Enzo e Saymon	07/02/2025	08/02/2025
Ideias v2	Saymon	06/02/2025	16/02/2025
Discussão Ideias v2	Enzo e Saymon	23/02/2025	25/02/2025
Discussão Ideias v1 e v2 - Análise Viável	Enzo e Saymon	07/02/2025	08/02/2025
Decisão Projeto Escribas	Enzo, Saymon e Professor Jorge	09/02/2025	11/02/2025
Planejamento	Enzo e Saymon	12/02/2025	14/02/2025
Pergunta de negócios e entendimento	Enzo e Saymon	15/02/2025	23/02/2025
Estrutura de Respostas	Enzo e Saymon	20/02/2025	25/02/2025
Pergunta que queremos responder	Enzo e Saymon	22/02/2025	01/03/2025
Fase 2 – Levantamento Técnico e Estudos			
Levantamento de Requisitos	Enzo	17/02/2025	22/02/2025
Ideias v1			
Levantamento de Requisitos	Saymon	17/02/2025	22/02/2025
Ideias v2			
Perguntas de Requisitos técnicos	Enzo e Saymon	26/02/2025	02/03/2025
Estudos de IA e Biblioteca	Enzo e Saymon	20/02/2025	02/03/2025
Estudos de Speech Recognition lib	Enzo e Saymon	06/03/2025	11/03/2025
Estudo de Whisper	Enzo e Saymon	26/03/2025	04/04/2025

Atividade	Responsáveis	Início	Término
Estudos de Microfone	Enzo e Saymon	26/03/2025	10/04/2025
Estudos de Google Cloud	Enzo e Saymon	06/03/2025	10/03/2025
Estudos de API - OpenAI	Enzo e Saymon	01/03/2025	13/03/2025
Estudos de API - Google Gemini	Enzo e Saymon	01/03/2025	11/03/2025
Estudos de API - DeepSeek	Enzo e Saymon	05/03/2025	12/03/2025
Fase 3 – Desenvolvimento e Testes			
Desenvolvimento 1º protótipo	Enzo e Saymon	07/03/2025	23/03/2025
Testes de 1º protótipo	Enzo e Saymon	19/03/2025	29/03/2025
Correções no protótipo	Enzo e Saymon	30/03/2025	12/04/2025
Resultados	Enzo e Saymon	15/04/2025	19/04/2025
Fase 4 – Documentação e Finalização			
Respostas	Enzo e Saymon	22/02/2025	23/03/2025
Estudo histórico sobre o problema	Enzo e Saymon	22/02/2025	22/03/2025
SUS - Brasil	Enzo e Saymon	22/02/2025	19/03/2025
Justificativa - Por que implementar?	Enzo e Saymon	05/03/2025	23/03/2025
Objetivo Direcional	Enzo e Saymon	05/03/2025	11/03/2025
Objetivo Mais amplo	Enzo e Saymon	15/03/2025	01/04/2025
Modelos de IA	Enzo e Saymon	09/04/2025	09/05/2025
Transcrição de Áudio	Enzo e Saymon	19/04/2025	16/05/2025
Whisper (Explicação, Descrição Matemática)	Enzo e Saymon	24/04/2025	21/05/2025
API - IA (Bibliotecas de tratamento de áudio)	Enzo e Saymon	30/04/2025	06/05/2025
Microfones (Tipos, Descrição Matemática)	Enzo e Saymon	22/04/2025	02/05/2025
Metodologia	—	12/05/2025	24/05/2025
Ajustes Finais da Documentação Parte 1	Enzo e Saymon	24/05/2025	29/05/2025




Figura 6 – Gráfico de Gantt do projeto *ESCRIBAS*.

A Figura 6 apresenta uma visualização gráfica do cronograma do projeto, construída no formato de Gráfico de Gantt. Essa representação destaca a distribuição temporal das principais etapas, desde o levantamento inicial de requisitos, passando pelos estudos técnicos, fases de desenvolvimento e testes, até a finalização da documentação desta etapa do projeto. A visualização proporciona uma leitura clara da sobreposição e sequência entre as atividades, evidenciando os períodos de maior carga de trabalho e os pontos decisivos do projeto. Para uma análise mais detalhada do cronograma, o Gráfico de Gantt completo está disponível em: https://senacspedu-my.sharepoint.com/:x:/g/personal/saymon_jsouza_senacsp_edu_br/EdqyYeSVsA1IsYQnHLSdQncBjzQ7xpa9VPVdvrGmDgPiZA?e=5Xsj5h. (Acesso em: 02 jun. 2025)

Referências

- [Baevski et al. 2020]BAEVSKI, A. et al. wav2vec 2.0: A framework for self-supervised learning of speech representations. *Advances in Neural Information Processing Systems (NeurIPS)*, v. 33, p. 12449–12460, 2020.
- [Federal 2018]FEDERAL, B. G. Lei - lei 13.709. *Lei Geral de Proteção de Dados Pessoais (LGPD)*, v. 12, n. 4, p. 1–14, 2018. Acesso em: 09 maio 2025. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>.
- [Ferreira e outros 2023]FERREIRA, R. J.; OUTROS. A sobrecarga administrativa na prática médica e o uso de tecnologias para otimização do tempo clínico. *Revista de Gestão em Saúde*, v. 15, n. 1, 2023.
- [Goyal, Gupta e Soni 2022]GOYAL, N.; GUPTA, S.; SONI, R. Benchmarking whisper for multilingual speech recognition tasks. *arXiv preprint arXiv:2212.04356*, 2022.
- [Juang e Rabiner 2004]JUANG, B. H.; RABINER, L. R. *Automatic Speech Recognition – A Brief History of the Technology Development*. 2004. https://web.ece.ucsb.edu/Faculty/Rabiner/ece259/Reprints/354_LALIASRHistory-final-10-8.pdf. Acesso em: 10 maio 2025.
- [Medicina 2019]MEDICINA, C. F. de. *Estudo sobre a espera por atendimento no SUS*. 2019. <https://portal.cfm.org.br>.
- [Oliveira e Lima 2022]OLIVEIRA, M. S.; LIMA, R. A. O impacto da rapidez no atendimento médico sobre a qualidade assistencial no sus. *Cadernos de Saúde Coletiva*, v. 30, n. 1, p. 45–53, 2022.
- [Omran 1971]OMRAN, A. R. The epidemiologic transition: A theory of the epidemiology of population change. *The Milbank Memorial Fund Quarterly*, v. 49, n. 4, p. 509–538, 1971.
- [PyAudio Documentation]PYAUDIO Documentation. <https://people.csail.mit.edu/hubert/pyaudio/docs/>. Acesso em: 11 maio 2025.
- [Rabiner 1989]RABINER, L. R. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, v. 77, n. 2, p. 257–286, 1989.
- [Radford e outros 2022]RADFORD, A.; OUTROS. *Robust Speech Recognition via Large-Scale Weak Supervision*. 2022. <https://cdn.openai.com/papers/whisper.pdf>. Acesso em: 10 maio 2025.

- [Saúde 2021]SAÚDE, M. da. *Plano Nacional de Saúde 2020–2023*. 2021. <https://www.gov.br/saude/pt-br/assuntos/planejamento-em-saude>.
- [Silva e colaboradores 2020]SILVA, J. L.; COLABORADORES. Análise das filas de espera no atendimento público de saúde no brasil. *Revista Brasileira de Saúde Pública*, v. 54, n. 2, p. 123–130, 2020.
- [Souza e Rocha 2021]SOUZA, A. L.; ROCHA, M. V. Automatização de registros médicos com ia: impacto na rotina clínica e na segurança do paciente. *Revista Brasileira de Informática em Saúde*, v. 17, n. 4, 2021.
- [Tomasi, Facchini e Piccini 2017]TOMASI, E.; FACCHINI, L. A.; PICCINI, R. X. Tempo de consulta médica na atenção primária à saúde no brasil: um estudo nacional. *Revista Brasileira de Medicina de Família e Comunidade*, v. 12, n. 39, 2017.
- [Vaswani et al. 2017]VASWANI, A. et al. Attention is all you need. *Advances in Neural Information Processing Systems*, v. 30, 2017.